

Dataset Obesity

Fernando José Gracia Choin

José Ángel Carretero Montes

Ismael Sallami Moreno

October 2024

1 Introducción

La obesidad es un problema de salud pública que ha adquirido proporciones alarmantes en las últimas décadas, afectando a personas de todas las edades y contextos socioeconómicos. Este fenómeno no solo está vinculado a un mayor riesgo de desarrollar enfermedades crónicas, como la diabetes tipo 2 y enfermedades cardiovasculares, sino que también representa una carga significativa para los sistemas de salud a nivel global. Para abordar este problema, es esencial entender los factores que influyen en su desarrollo. En este trabajo, se propone la construcción de un modelo econométrico cuyo objetivo es estimar el grado de obesidad en función de diversas variables relacionadas con características individuales y hábitos de vida. Entre las variables incluidas en el análisis se encuentran la edad, altura, peso, antecedentes familiares de sobrepeso, hábitos alimenticios, nivel de actividad física, consumo de agua, uso de dispositivos tecnológicos, y otros factores clave que pueden contribuir a la obesidad. A través de este enfoque, se busca identificar los determinantes más relevantes que influyen en la obesidad, lo que podría facilitar la implementación de políticas y estrategias de intervención más eficaces para combatir este problema creciente.

2 Variables

2.1 Dependientes

El objetivo del modelo será estimar el **grado de obesidad** en función de varias variables. Por tanto, la variable dependiente será cualquiera que represente de forma fiel el grado de obesidad que sufra un determinado individuo. Por tanto, la variable/variables dependientes serán el peso, el índice de masa corporal (*IMC*) o cualquiera similar.

2.2 Independientes

Para estimar el grado de obesidad de una persona, hemos identificado las siguientes variables independientes como relevantes:

- **Edad (Age):** Variable continua que representa la edad de la persona.
- **Altura (Height):** Variable continua que representa la altura de la persona.
- **Peso (Weight):** Variable continua que representa el peso en kilogramos.
- **Antecedentes familiares de sobrepeso (family_history_with_overweight):** Variable binaria que indica si algún familiar ha sufrido o sufre de sobrepeso.
- **Consumo frecuente de alimentos calóricos (FAVC):** Variable binaria que indica si la persona consume frecuentemente alimentos altos en calorías.
- **Consumo de vegetales (FCVC):** Variable entera que indica la frecuencia con la que la persona consume vegetales en sus comidas.
- **Número de comidas principales (NCP):** Variable continua que indica cuántas comidas principales tiene la persona al día.
- **Consumo de alimentos entre comidas (CAEC):** Variable categórica que indica si la persona consume alimentos entre comidas.
- **Consumo de agua (CH2O):** Variable continua que indica la cantidad de agua que la persona bebe diariamente.
- **Actividad física (FAF):** Variable continua que indica la frecuencia con la que la persona realiza actividad física.
- **Uso de dispositivos tecnológicos (TUE):** Variable entera que indica la cantidad de tiempo que la persona utiliza dispositivos tecnológicos como teléfonos móviles, videojuegos, televisión, entre otros.
- **Consumo de alcohol (CALC):** Variable categórica que indica con qué frecuencia la persona consume alcohol.
- **Medio de transporte (MTRANS):** Variable categórica que indica el medio de transporte que la persona utiliza usualmente.

3 Detalles de la Base de Datos

3.1 Delimitar el tema sobre el que se desea trabajar

El tema central de este estudio es analizar y predecir el **grado de obesidad** en la población a partir de diversos factores relacionados con el estilo de vida,

los hábitos alimenticios y las características físicas. Este trabajo se centrará en identificar las variables más relevantes que influyen en el desarrollo de la obesidad, así como en construir un modelo que permita predecir el nivel de obesidad en base a dichas variables.

El estudio se enfoca en el análisis de datos obtenidos de individuos de diversas edades y antecedentes, utilizando un conjunto de variables independientes que incluyen factores como la actividad física, el consumo de alimentos y agua, entre otros.

3.2 Búsqueda de bibliografía básica sobre el tema

Para este estudio, se ha utilizado un **dataset** obtenido de la plataforma **Kaggle**, la cual es conocida por proporcionar conjuntos de datos de alta calidad en una amplia variedad de campos. El **dataset** en cuestión contiene información detallada sobre variables relacionadas con la obesidad y los hábitos de vida de individuos.

Enlace: <https://www.kaggle.com/datasets/fatemehmehrpavar/obesity-levels>

3.3 Especificación inicial del modelo.

El modelo econométrico propuesto sigue la forma de un **modelo lineal múltiple**, que se puede expresar de la siguiente manera:

$$Y_t = \beta_0 + \beta_1 \cdot Edad_t + \beta_2 \cdot Altura_t + \beta_3 \cdot Peso_t + \beta_4 \cdot AntFam_t + \beta_5 \cdot FAVC_t + \dots + \beta_k \cdot X_{kt} + u_t \quad (1)$$

Donde:

- Y_t representa el **grado de obesidad** de la persona t , que es nuestra variable dependiente.
- β_0 es el **término independiente**, que refleja el valor esperado de Y_t cuando todas las variables explicativas son iguales a cero.
- $\beta_1, \beta_2, \beta_3, \dots, \beta_k$ son los **coeficientes de regresión** que indican el cambio promedio en Y_t dado un cambio en cada variable explicativa.
- X_{kt} son las **variables independientes** del modelo (Edad, Altura, Peso, Antecedentes familiares, etc.).
- u_t es el **término de error**, que capta los factores no observados que influyen en el grado de obesidad y no están recogidos por las variables explicativas.

Cada uno de los coeficientes β_k mide el impacto parcial de la correspondiente variable explicativa en el grado de obesidad, manteniendo las demás constantes.

Por ejemplo, β_3 mide el efecto marginal del peso sobre la obesidad, controlando por edad, altura y las demás variables.

Este modelo lineal múltiple permitirá estimar cómo estos factores influyen en el grado de obesidad y evaluar cuáles son los más significativos.

Para estimar los parámetros, usaremos el método de mínimos cuadrados ordinarios:

El modelo de **Mínimos Cuadrados Ordinarios (MCO)** es una técnica econométrica ampliamente utilizada para estimar los parámetros de un modelo lineal. Este método se basa en la minimización de la suma de los cuadrados de las diferencias entre los valores observados y los valores predichos por el modelo. En el contexto de nuestro estudio sobre el grado de obesidad, utilizaremos MCO para estimar cómo las variables independientes, como la edad, altura, peso y hábitos de alimentación, influyen en la variable dependiente, que es el grado de obesidad.

La ventaja del MCO radica en su simplicidad y en la capacidad de proporcionar estimaciones eficientes y consistentes de los parámetros del modelo, siempre que se cumplan ciertos supuestos, como la linealidad, la homocedasticidad y la independencia de los errores.

En la *figura 1* se presenta un gráfico que ilustra la relación entre una variable independiente (por ejemplo, el peso) y el grado de obesidad, donde se puede observar la nube de puntos y la recta de regresión que representa la relación estimada por el modelo.




Figure 1: Nube de puntos y recta de regresión que representa la relación entre el peso y el grado de obesidad.

3.4 Disponibilidad de datos del fenómeno.

Para el estudio vamos a usar una base de datos de naturaleza de sección cruzada o también conocida como **transversal**, la cual consiste en datos de múltiples

individuos observados en un mismo instante de tiempo.

3.5 **Ámbito de aplicación.**

Hemos escogido una base de datos la cual se corresponde a un **ámbito local**, por ello esto nos permite estudiar la obesidad, y que factores influyen en ella, en las zonas geograficas de Perú, Colombia y México.

4 **Elaboración de la Base de Datos**

4.1 **Datos Extraños**

En este caso hay ciertos datos que no concuerdan con la lógica real, como puede ser el caso de pesos fuera de lo común y otras variables con valores extraños. Por ende, a la hora de realizar el modelo tendremos cuidado con estos casos.